TRABAJO INTEGRADOR FINAL

Refactorización de código para poner en producción un modelo de ML

Una de las principales tareas que debe abordar un machine learning engineer (MLE) es interpretar el código desarrollado por los científicos de datos (DS) y ser capaz de refactorizarlo para convertirlo en una pieza de software confiable y bien estructurado.

Para poner en práctica estas habilidades suponga que se ha incorporado a un equipo de datos que se encuentra desarrollando un modelo de ML para predecir ventas. El equipo ya entrenó su primer modelo de regresión simple para cumplir con las métricas definidas en conjunto con el negocio, y le han pedido que refactorice el código para poder comenzar a realizar las pruebas del modelo.

Para que pueda comenzar con la tarea solicitada el DS le ha enviado un archivo comprimido que contiene:

- El dataset con datos sobre las transacciones utilizadas para definir y entrenar el modelo.
- La notebook desarrollada por él con el análisis exploratorio de datos, las transformaciones realizadas y el modelo entrenado.
- Un archivo .json con un ejemplo de entrada al proceso de predicción.

Dentro del notebook encontrará los siguientes pasos que deberá ordenar en distintos bloques/módulos de código para poder crear un pipeline que procese nuevos datos de entrada:

- FEATURE ENGINEERING: para los años de establecimiento
- LIMPIEZA: unificando etiquetas para 'Item_Fat_Content'
- LIMPIEZA: faltantes en el peso de los productos
- LIMPIEZA: faltantes en el tamaño de las tiendas
- FEATURE ENGINEERING: asignación de nueva categoría para 'Item_Fat_Content'
- FEATURE ENGINEERING: creando categorías para 'Item_Type'
- FEATURE ENGINEERING: codificación los niveles de precios de los productos
- FEATURE ENGINEERING: codificación de variables ordinales
- FEATURE ENGINEERING: codificación de variables nominales
- ENTRENAMIENTO

Se propone, aunque no es mandatorio, un esquema de scripts como el siguiente:

Pipeline de entrenamiento

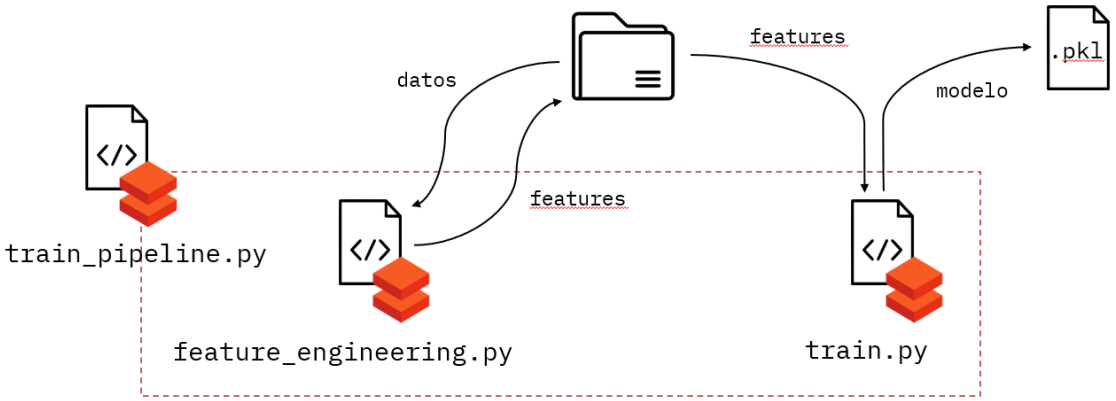

Pipeline de inferencia

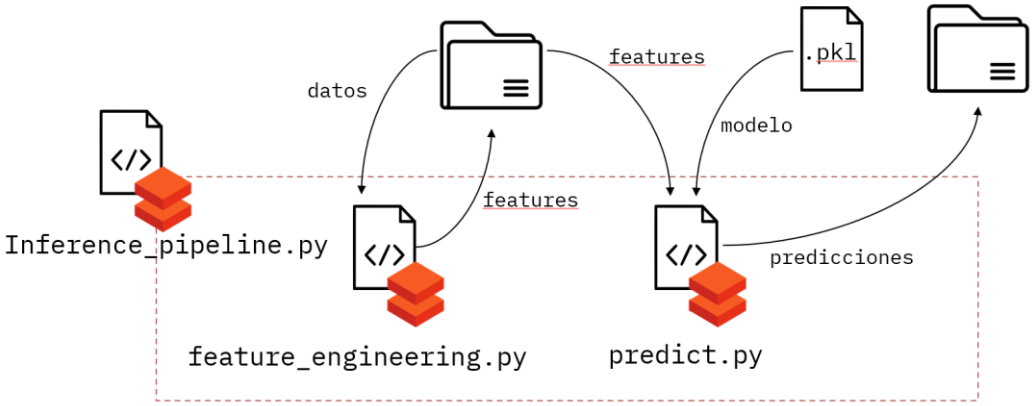

*La implementación en Databricks es **opcional**.*

Una vez desarrollada y probada la implementación elegida, utilizar alguno de los frameworks vistos para optimización de hiperparámetros (HPs) y realizar un ajuste fino del modelo. También se puede proponer una arquitectura que mejore las métricas.

El ajuste de HPs puede ser realizado en una notebook aparte, **no es necesario que ese nuevo modelo se incorpore a los pipelines.** La notebook con el ajuste de HPs se debe guardar en la carpeta “Notebook”.

Entregables esperados:

Desarrollo de pipeline de procesamiento: script/s de Python que permita/n procesar los datos de entrada que están en formato json. Dentro de estos scripts se deben respetar las transformaciones y los procesos implementados por el DS.

Pruebas: la ejecución del pipeline debe poder realizarse con una llamada desde consola.

Calidad del producto: se deben aplicar la mayor cantidad de buenas prácticas posibles siguiendo los estándares vistos en el curso.

Documentación: cada función y módulo de Python debe tener su docstring correspondiente. Agregar comentarios in-line según se considere necesario para aclarar la ejecución del código. Agregar un readme sencillo para aclarar el modo de uso del código.

Formato de entrega:
Opc. 1: el trabajo deberá ser subido a su repositorio personal y agregar como colaborador del proyecto al usuario AlexBarria. Deberán ir haciendo los commits a medida que vayan avanzando y al final del proceso realizar un PR. La aprobación del PR quedará a cargo del docente una vez que se resuelvan todas correcciones del PR.

Opc. 2: comprimir todos los archivos del proyecto en un .zip/.rar y enviarlo por mail al docente (alexbarria_14@hotmail.com).

Lineamientos y recomendaciones:

- Prestar especial atención a las buenas prácticas de programación vistas a lo largo de la materia.
- Usar las herramientas pylint y autopep8 para lograr scripts prolijos y ordenados.
- Agregar loggins puede favorecer la tarea de depurar el código.
- Para verificar que las tareas de refactorización no afectaron el desarrollo del DS, se pueden calcular las métricas del modelo antes y después de la refactorización. Estas métricas deberían ser iguales.
- En la medida de lo posible, mantener los comentarios y la documentación en inglés.
- Para el manejo de argumentos entre los scripts se puede utilizar el módulo argparse de Python.
- Generar un archivo requirements.txt puede ayudar a que otro usuario pueda ejecutar su código con todas las dependencias necesarias.

Evaluación:

El trabajo puede ser realizado en grupos de hasta 3 personas.

La nota del TP representa un %60 de la nota total para la aprobación de la materia. El resto de la nota de la materia será dividida en partes iguales entre los formularios de Google de cada clase.

La fecha máxima de entrega será la última clase del bimestre donde haremos una breve puesta en común del trabajo (no es necesario preparar ningún tipo de presentación).